


AI-Guided Semantic Mutation Testing for RAG

Trình bày: **Nguyễn Quốc Huy (PL)** · Ngày: **2026-06-14**

TOPIC CODE: RT-SWT-001

NHÓM 6



Problem & GAP

Bối cảnh

Hệ thống RAG trong các ứng dụng doanh nghiệp ngày càng phổ biến, đòi hỏi kiểm thử độ bền bỉ khắt khe.

Hạn chế hiện tại

Các kỹ thuật đánh giá độ bền bỉ (robustness) hiện tại còn hạn chế, khó định lượng khả năng chống chịu trước dữ liệu sai lệch.

Nghiên cứu liên quan

Momtaz (2026) tiên phong dùng Mutation Testing cho RAG nhưng chỉ dừng ở đột biến rule-based. Ngược lại, Wang (2026) chứng minh LLM sinh đột biến ngữ nghĩa tốt hơn hẳn.

Technology Gap

Chưa có nghiên cứu ứng dụng LLM sinh **Đột biến Ngữ nghĩa (Semantic Mutation)** để đánh lừa RAG.

Motivation

Lấp đầy GAP để tránh "**ảo tưởng an toàn**" trước dữ liệu sai lệch tinh vi mà System Prompt không thể nhận diện.

Evidence Summary

Tool / LLM (Paper)	Metric	Kết quả chính
GPT-4, Llama-2 (Momtaz 2026)	Hallucination Rate, Abstain Rate	Abstain rate đạt 66% khi xóa System Prompt
SMART (Wang 2026)	Mutant Score	Tăng 15% Mutant Score so với rule-based
SLR (Chu 2026)	N/A	Xác định 5 xu hướng GenAI trong SE
LLM Fuzzer (Moran 2023)	Coverage	Phát hiện 23 bug mới
RAGAS (Chen 2024)	Faithfulness, Relevance	85% tương quan với chuyên gia

Research Questions & Hypotheses

RQ1

[P: Hệ thống AnythingLLM + FastAPI Docs] + **[I:** Tiêm Semantic Mutations từ Qwen 3] có bộc lộ **[O:** Tỷ lệ ảo giác gia tăng đáng kể so với Rule-based] không?

H0: Tỷ lệ ảo giác (Semantic) $\leq$ (Rule-based)

H1: Tỷ lệ ảo giác (Semantic) $>$ (Rule-based)

Metric: Hallucination Rate

Threshold: Cohen's $d > 0.5$ (Case 1)

Test: Wilcoxon signed-rank $\alpha = 0.05$

RQ2

[P: Hệ thống AnythingLLM + System Prompt chuẩn] + **[I:** Đối mặt Semantic Mutations từ Qwen 3] có duy trì được **[O:** Tỷ lệ từ chối $\geq 90\%$] không?

H0: [System Prompt] DUY TRÌ Abstain Rate $\geq 90\%$


H1: [System Prompt] KHÔNG DUY TRÌ Abstain Rate $\geq 90\%$

Metric: Abstain Rate

Threshold: 90% (Case 3)

Test: Binomial test $\alpha = 0.05$

Experiment Pipeline



Dataset & Baseline Setup



Dataset ✓

FastAPI Official Documentation | **N = 416** (32 Contexts/Queries × 13 Mutations) | Accessible

AI Models ✓

Qwen 3 (Mutator) & **DeepSeek V4** (Judge) | **N = 2** API Keys | Ready

Baseline System ✓

AnythingLLM Desktop (tích hợp Llama 4 Scout) | **N = 1** Workspace | Installed

Baseline Mutation ✓

Rule-based Mutation (Cắt xén ngẫu nhiên - NLTK) từ Momtaz (2026) | Scripted

Measurement Validation

Cohen's Kappa ($k > 0.60$) cho đánh giá chéo giữa Human và AI Judge.

Statistical Plan

Mục tiêu / Tham số	Kỹ thuật Thống kê áp dụng	Điều kiện / Giá trị
Test (RQ1)	Wilcoxon signed-rank (One-tailed)	Paired samples, Non-parametric
Test (RQ2)	Binomial test	Pass/Fail proportion (Ngưỡng tuyệt đối 90%)
Mức ý nghĩa (α)	0.05	Định dạng chuẩn cho cả 2 RQ
Effect Size	Cohen's d	Áp dụng đo lường khác biệt cho RQ1
Năng lực (Power)	Power ≥ 0.80 (với $N = 416$)	Đảm bảo độ tin cậy của mẫu phi tham số

Threats to Validity

Internal Threat

Model version drift & Lỗi cú pháp từ Qwen 3 API

Mitigation: Cố định phiên bản API (qwen-3) & Lọc cú pháp bằng Regex trước khi nạp VectorDB.

Construct Threat

LLM Judge (DeepSeek V4) dán nhãn sai lệch (Annotation bias)

Mitigation: Đánh giá mù (Blind eval) thủ công N=40 mẫu → Yêu cầu hệ số đồng thuận Cohen's Kappa $k > 0.60$.

Conclusion Threat

Cỡ mẫu nhỏ gây hụt Năng lực kiểm định thống kê (Statistical Power)

Mitigation: Cấu trúc thực nghiệm ép sinh đủ N=416 mẫu ghép cặp → Đảm bảo Power ≥ 0.80 .



Timeline & Phân công thực thi (Tuần 5–10)

Tuần 5–6: Preparation

Hoàn thiện Proposal, Lọc dữ liệu FastAPI, Thiết lập API

Checkpoint: proposal.md v1.0, Thư mục data/raw/

Role: PL, DG, LR, RW

Tuần 8: Full Batch

Vận hành 416 mẫu đột biến, Phân tích kiểm định thống kê

Checkpoint: full_analysis.ipynb (p-value), Biểu đồ khoa học

Role: DG, LR, MS, RW

Tuần 7: Pilot Test

Lập Ground truth (Mù đôi), Chạy thử nghiệm, Đánh giá

Checkpoint: pilot_analysis.ipynb, Tài liệu Amendment

Role: DG, LR, MS, PL

Tuần 9–10: Wrap-up

Biên soạn báo cáo tổng kết & Xây dựng Slide bảo vệ


Checkpoint: Báo cáo cuối kỳ, Slide Gamma

Role: Tất cả



Ghi chú: **PL** (Điều phối/Nộp bài), **DG** (Data/Ground truth), **LR** (Vận hành LLM API), **MS** (Metric & Thống kê), **RW** (Viết báo cáo/Biểu đồ).

Expected Contribution



LLM-as-a-Hacker

Cung cấp phương pháp đánh giá RAG tự động bằng AI (LLM-as-a-Hacker).



Điểm mù System Prompt

Xác định điểm mù thực sự của System Prompt trước thông tin sai lệch tinh vi.

